T.C.
FIRAT ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ

SENTINEL-2 UYDU GÖRÜNTÜLERİNDEN ÇOK SPEKTRALLİ VERİLER VE DERİN ÖĞRENME İLE SU KÜTLELERİNİN SEGMENTASYONU

Melih UĞURLU
Enes BOZDAĞ

Tez Danışmanı
Prof. Dr. İlhan AYDIN

BİTİRME TEZİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

ELAZIĞ
2026

T.C.

FIRAT ÜNİVERSİTESİ

MÜHENDİSLİK FAKÜLTESİ

SENTINEL-2 UYDU GÖRÜNTÜLERİNDEN ÇOK SPEKTRALLİ VERİLER VE DERİN ÖĞRENME İLE SU KÜTLELERİNİN SEGMENTASYONU

Melih UĞURLU

Enes BOZDAĞ

BİTİRME TEZİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Bu bitirme tezi …../……/2026 tarihinde, aşağıda belirtilen jüri tarafından oybirliği/oyçokluğu ile başarılı/başarısız olarak değerlendirilmiştir.

(İmza)	(İmza)	(İmza)
Prof. Dr. İlhan AYDIN	Üye	Üye

ÖZGÜNLÜK BİLDİRİMİ

Bu çalışmada, başka kaynaklardan yapılan tüm alıntıların, ilgili kaynaklar referans gösterilerek açıkça belirtildiğini, alıntılar dışındaki bölümlerin, özellikle projenin ana konusunu oluşturan teorik çalışmaların ve yazılımın benim tarafımdan yapıldığını bildiririm.

Fırat Üniversitesi

Bilgisayar Mühendisliği Bölümü

23119 Elazığ

03.02.2026

Melih Uğurlu

Enes Bozdağ

BENZERLİK BİLDİRİMİ

Melih_Uğurlu-Enes_Bozdağ-Bitirme

ORİJİNALLİK RAPORU

%1	%1	%0	%0
BENZERLİK ENDEKSİ	İNTERNET KAYNAKLARI	YAYINLAR	ÖĞRENCİ ÖDEVLERİ

BİRİNCİL KAYNAKLAR

1	Submitted to Universidade Aberta Öğrenci Ödevi	<%1
2	polen.itu.edu.tr İnternet Kaynağı	<%1
3	search.trdizin.gov.tr İnternet Kaynağı	<%1
4	www.repositorio.ufc.br İnternet Kaynağı	<%1
5	hindi.tsijournals.com İnternet Kaynağı	<%1
6	www.duvaryayinlari.com İnternet Kaynağı	<%1

TEŞEKKÜR

Sentinel-2 uydu görüntüleri ve derin öğrenme teknikleri kullanılarak su kütlelerinin segmentasyonunun gerçekleştirildiği bu bitirme projesi, mühendislik eğitimimiz boyunca edindiğimiz teorik bilgileri pratiğe dökme ve literatüre katkı sağlama noktasında bizlere önemli bir deneyim kazandırmıştır.

Projenin konusunun belirlenmesinden sonuçlandırılmasına kadar geçen süreçte; engin bilgi birikimi, tecrübesi ve değerli yönlendirmeleriyle bize yol gösteren, karşılaştığımız her türlü zorlukta desteğini esirgemeyen değerli danışman hocamız Prof. Dr. İlhan Aydın'a en içten teşekkürlerimizi sunarız.

Eğitim hayatımız boyunca akademik gelişimimize katkı sağlayan Fırat Üniversitesi Bilgisayar Mühendisliği Bölümü'nün değerli öğretim üyelerine ayrıca teşekkür ederiz. Aynı zamanda hayatımızın her aşamasında olduğu gibi bu zorlu süreçte de maddi ve manevi destekleriyle daima yanımızda olan, sabır ve fedakarlıklarıyla bize güç veren kıymetli ailelerimize ve arkadaşlarımıza teşekkürü bir borç biliriz.

İÇİNDEKİLER

Sayfa No

ÖZGÜNLÜK BİLDİRİMİ ..... **I**
BENZERLİK BİLDİRİMİ ..... **II**
TEŞEKKÜR ..... **III**
İÇİNDEKİLER ..... **IV**
ŞEKİLLER LİSTESİ ..... **VI**
TABLOLAR LİSTESİ ..... **VII**
KISALTMA LİSTESİ ..... **VIII**
ÖZET ..... **IX**
ABSTRACT ..... **X**
1. GİRİŞ **1**
1.1. Su Krizinin Boyutu ve Önemi 1
1.2. Uzaktan Algılamanın Rolü 3
1.3. Mevcut Yöntemlerin Kısıtları ve Makine Öğrenmesi İhtiyacı 4
1.4. Çalışmanın Amacı 5
2. GENEL BİLGİLER **7**
2.1. Uzaktan Algılama 7
2.1.1. Tarihçe ve Gelişim 7
2.1.2. Elektromanyetik Spektrum ve Algılama Mantığı 8
2.1.3. Aktif ve Pasif Sensörler 9
2.2. Sentinel-2 Uydu Misyonu 9
2.2.1. MultiSpectral Instrument (MSI) 9
2.2.2. SWIR (kısa dalga kızılötesi) bandı 10
2.2.3. Makine Öğrenmesi 10
2.2.4. Yapay Sinir Ağları Temelleri 10
2.2.5. Backpropagation (Geri Yayılım) Algoritması 10
2.3. Evrişimli Sinir Ağları (CNN) 11
2.3.1. Konvolüsyon Katmanı 11
2.3.2. Havuzlama Katmanı 11
2.4. Semantik Segmentasyon 12
3. MATERYAL VE YÖNTEM **14**
3.1. Veri Seti Oluşturma Süreci ve Karşılaşılan Zorluklar 14
3.1.1. Başlangıç Hatası: RGB ve JPEG Kullanımı 14
3.1.2. Hazır Veri Seti Deneyimi (Polonya Gölleri) 15

3.1.3. Nihai Çözüm: Ham TIFF Formatı ve SWIR Bandı Entegrasyonu 15
3.2. Teknik Altyapı ve Kütüphaneler 16
3.3. Veri Ön Süreci 17
3.3.1. Kanal Birleştirme 17
3.3.2. Uzamsal Çözünürlük ve Veri Tutarlılığı 18
3.3.3. Etiketleme ve İnsan Faktörü 18
3.3.4. Maske Oluşturma ve Etiketleme 19
3.3.5. Veri Yükleme Stratejisi ve Bellek Yönetimi 20
3.3.6. Dinamik Veri İşleme ve Veri Artırma (Data Augmentation) 21
3.4. Model Mimarisi: U-Net Tasarımı 23
3.4.1. Eğitim Konfigürasyonu ve Hiperparametreler 24
3.4.2. Eğitim Stratejisi ve Optimizasyon 26
3.4.3. Arayüz Geliştirme (GUI) 27
3.5. Algoritmik Akış ve Sistemin Çalışma Mantığı 28
4. BULGULAR VE TARTIŞMA 30
4.1. Sayısal Bulgular 30
4.2. Görsel Analizler ve SWIR Etkisi 31
4.3. Donanım Performans Analizi 32
4.4. Karşılaştırma 32
5. SONUÇ VE ÖNERİLER 33
5.1. Sosyal Etki ve Sürdürülebilirlik 33
5.2. Gelecek Çalışmalar İçin Öneriler 34
KAYNAKLAR 35
ÖZGEÇMİŞ 37

ŞEKİLLER LİSTESİ

Sayfa No

Şekil 1.1. Türkiye Su Stresi Haritası....2
Şekil 1.2. NDWI Test Görüntüsü....4
Şekil 2.1. Salda Gölü RGB Ve IR....8
Şekil 3.1. Bir jpeg görüntünün maskesiz hali....14
Şekil 3.2. Bir jpeg görüntünün maskeli hali....15
Şekil 3.3. Göllerin Türkiye Haritası Üzerindeki Dağılımı....16
Şekil 3.4. Kanal birleştirme kodu....18
Şekil 3.5. 16 bit 1 bit dönüşümü....20
Şekil 3.8. U-Net modelinin PyTorch tabanlı sınıf yapısı ve mimari detayları....24
Şekil 3.9. Eğitim parametreleri kod bloğu....25
Şekil 3.10. Eğitim Döngüsü ve Geri Yayılım Algoritması Kod Bloğu....27
Şekil 4.1. Burdur gölü 2015....31
Şekil 4.2. Burdur gölü 2025....31

TABLOLAR LİSTESİ

Sayfa No

Tablo 4.1. Eğitim ve Doğrulama Setleri İçin Kayıp Değerlerinin Zamansal Analizi 30
Tablo 4.2. Model Performans Metrikleri 32

KISALTMA LİSTESİ

CNN : Convolutional Neural Network (Evrişimli Sinir Ağı)

DL : Deep Learning (Derin Öğrenme)

ESA : European Space Agency (Avrupa Uzay Ajansı)

IoU : Intersection over Union (Birlik Üzerinden Kesişim)

MSI : Multispectral Instrument

NDWI : Normalized Difference Water Index

NIR : Near Infrared (Yakın Kızılötesi)

RGB : Red Green Blue (Kırmızı Yeşil Mavi)

SWIR : Short Wave Infrared (Kısa Dalga Kızılötesi)

YSA : Yapay Sinir Ağları

ÖZET

Su kaynaklarının sürdürülebilir yönetimi, küresel iklim değişikliği ve artan kuraklık riski nedeniyle büyük önem taşımaktadır. Geleneksel uzaktan algılama yöntemleri, değişken çevresel koşullarda ve karmaşık coğrafyalarda yetersiz kaldığı durumlar bulunmaktadır. Bu çalışmamızda, Sentinel-2 uydu görüntüleri ve Derin Öğrenme teknikleri kullanılarak su kütlelerinin otonom ve yüksek doğrulukla tespit edilmesi amaçlanmıştır. Bu sayede büyük bir insan grubuna ihtiyaç duyularak yapılacak uzun süren araştırmalar basit ve hızlı hale getirilebilecektir. Proje kapsamında Türkiye coğrafyasına özgü, boyutları değişken 69 gölü içeren özgün bir veri seti oluşturduk. Bunun sebebi veri setlerinin Türkiye'nin özgün göl yapılarını desteklenmeyip daha öznel oluşturulmasıdır. Veri analizleri sonucunda RGB bantlarının yetersizliği tespit edilmiş ve modele Kısa Dalga Kızılötesi (SWIR) entegre edilerek, karlı dağların veya parlak yüzeylerin su ile karıştırılması problemi çözülmüştür. Geliştirilen U-Net mimarili model, %93 üzerindeki IoU başarısı ile literatürdeki standart yöntemlerden daha kararlı sonuçlar vermiştir. Ayrıca geliştirdiğimiz masaüstü arayüzü ile modelin son kullanıcılar tarafından kolayca kullanılması sağlanmaktadır. Elde edilen bulgular, yapay zeka destekli uzaktan algılama sistemlerinin su yönetimi stratejilerinde etkin bir araç olabileceğini göstermektedir.

Anahtar Kelimeler: Derin Öğrenme, Sentinel-2, Segmentasyon, U-Net, SWIR, Uzaktan Algılama.

ABSTRACT

Sustainable management of water resources is of great importance due to global climate change and increasing drought risk. There are cases where traditional remote sensing methods fall short under variable environmental conditions and in complex geographies. In this study, it is aimed to detect water bodies autonomously and with high accuracy using Sentinel-2 satellite images and Deep Learning techniques. In this way, long-term research requiring a large group of people can be made simple and fast. Within the scope of the project, we created a unique dataset containing 69 lakes of various sizes specific to Turkey's geography; the reason for this is that the datasets do not support Turkey's unique lake structures and are created specifically for mountains. As a result of data analyses, the insufficiency of RGB bands was determined, and by integrating Short Wave Infrared (SWIR - Band 11) into the model, we solved the problem of confusing snowy mountains or bright surfaces with water. The U-Net architecture model we developed yielded more stable results than standard methods in the literature with an IoU success rate of over 93%. Additionally, with the desktop interface we developed, the model is enabled to be easily used by end-users. The obtained findings show that AI-supported remote sensing systems can be an effective tool in water management strategies.

Keywords: Deep Learning, Sentinel-2, Segmentation, U-Net, SWIR, Remote Sensing.

1. GİRİŞ

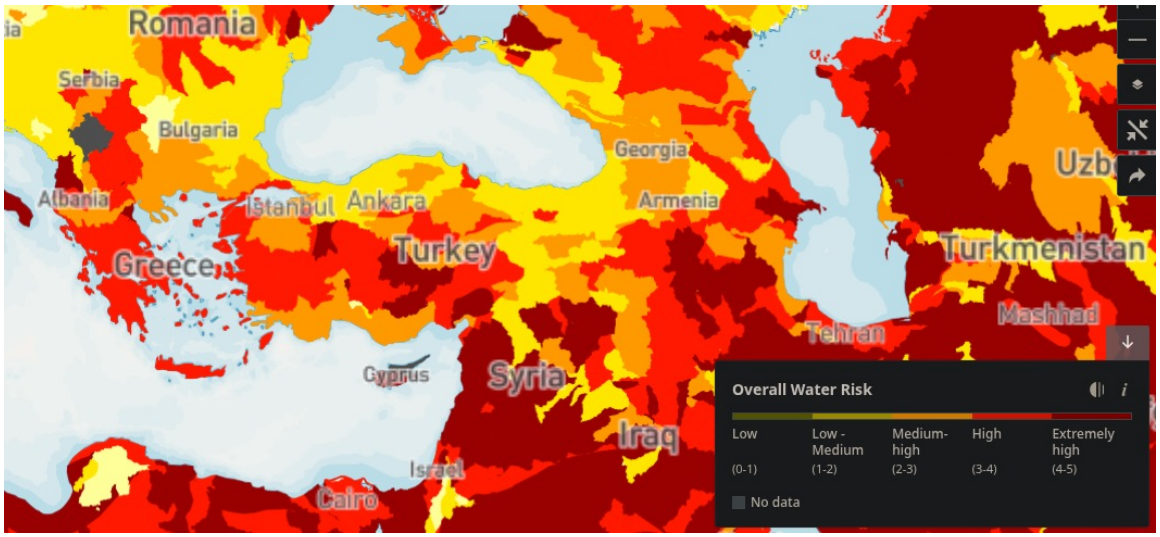
1.1. Su Krizinin Boyutu ve Önemi

Su, yalnızca biyosferdeki yaşamın biyokimyasal temelini oluşturmakla kalmaz; aynı zamanda tarımsal gıda güvenliği, enerji üretimi, endüstriyel soğutma sistemleri, ulaşım ve ekosistem hizmetlerinin sürekliliği için ikame edilemez, stratejik bir doğal kaynaktır. Medeniyetlerin gelişimi ve çöküşü tarihsel olarak suyun varlığıyla doğrudan ilişkili olmuştur. Ancak 21. yüzyılda insanlık, tarihte eşi görülmemiş bir hidrolojik belirsizlik dönemiyle karşı karşıyadır. Antropojenik (insan kaynaklı) etkilerle ivme kazanan iklim değişikliği, plansız ve dikey şehirleşme, kontrolsüz nüfus artışı, tarımda vahşi sulama yöntemleri ve sanayileşmenin getirdiği ağır metal kirliliği gibi faktörler, "Su-Enerji-Gıda" sacayağını tehdit eden çok katmanlı, karmaşık ve geri döndürülmesi zor bir küresel su krizini tetiklemiştir.

Birleşmiş Milletler, Hükümetler arası İklim Değişikliği Paneli ve Dünya Sağlık Örgütü tarafından yayımlanan güncel raporlar, mevcut tüketim alışkanlıklarının ve "iş olağan" senaryolarının devam etmesi durumunda, 2050 yılına kadar dünya nüfusunun yarısından fazlasının fiziksel veya ekonomik su kıtlığı riskiyle yüzleşeceğini öngörmektedir. Su kıtlığı, sadece içme suyuna erişim sorunu değil, aynı zamanda sanitasyon eksikliğine bağlı salgın hastalık riskini ve gıda üretimindeki düşüşü beraberinde getirmektedir. Özellikle Ortadoğu ve Akdeniz Havzası gibi kurak ve yarı kurak iklim kuşaklarında yer alan bölgeler için bu durum, sadece çevresel bir sorun olmaktan çıkıp; kitlesel iklim göçlerine, sınır aşan sular sorununa ve bölgesel istikrarsızlıklara yol açabilecek bir ulusal güvenlik meselesine dönüşmüştür.

Türkiye, jeopolitik konumu itibarıyla üç tarafı denizlerle çevrili ve Fırat-Dicle gibi zengin akarsu havzalarına kaynaklık etmesi nedeniyle kamuoyunda yanlış bir algıyla "su zengini" bir ülke olarak nitelendirilmektedir. Oysa Devlet Su İşleri verileri ve uluslararası standartlar incelendiğinde; kişi başına düşen yıllık kullanılabilir su miktarının 2000'li yılların başında 1.650 m^3 iken, günümüzde yaklaşık 1.300 m^3 seviyelerine gerilediği ve teknik olarak "su stresi" yaşayan ülkeler kategorisinde yer aldığı görülmektedir (Şekil 1.1). Nüfus projeksiyonları, 2030 yılında bu değerin 1.100 m^3'ün altına düşerek Türkiye'nin "su fakiri" ülkeler sınıfına gireceğini işaret etmektedir. Küresel ısınmaya bağlı olarak artan ortalama yüzey sıcaklıkları, buharlaşma-terleme oranlarını kritik seviyelere taşırken; yağış rejimlerindeki düzensizlikler (şiddetli sağanaklar şeklinde yağan verimsiz yağmurlar ve uzun süreli kuraklıklar) ve kar örtüsünün azalması, yeraltı akiferlerinin ve yerüstü su rezervlerinin beslenmesini engellemektedir. Bu bağlamda, stratejik

tatlı su rezervleri olan göllerin, barajların ve sulak alanların sınır değişimlerinin anlık, doğru, tekrarlanabilir ve sürdürülebilir bir şekilde izlenmesi bir tercih değil, hayati bir zorunluluk arz etmektedir.



Şekil 1.1. Türkiye Su Stresi Haritası

Geleneksel hidrolojik izleme ve haritalama yöntemleri, tarihsel olarak yerinde saha ölçümlerine, limnigraflara (su seviye ölçüm istasyonları), batimetrik çalışmalara veya manuel fotogrametrik haritalama tekniklerine dayanmaktadır. Ancak bu konvansiyonel yöntemler, günümüzün dinamik ihtiyaçları, artan veri talebi ve karar alma süreçlerinin hızı karşısında yetersiz kalmaktadır:

- Zaman ve Ölçek Maliyeti: Geniş havzalarda veya binlerce kilometrekarelik göl yüzeylerinde (Örneğin: Van Gölü 3.713 km² veya Tuz Gölü) veri toplamanın günler hatta haftalar sürmesi, verinin işlendiği anda güncelliğini yitirmesine neden olabilmektedir. Dinamik su yüzeylerinin anlık değişimini veya ani taşkınların yayılımını yakalamak bu statik yöntemlerle imkansızdır.
- Ekonomik Yük: Düzenli ve sık aralıklı saha çalışmaları için gereken nitelikli personel (hidrolog, harita mühendisi), arazi araçları, yakıt ve hassas teknik ekipman lojistiği, özellikle gelişmekte olan ülkelerin sürdürülebilir kamu bütçelerini aşan yüksek maliyetler doğurmaktadır.
- İnsan Hatası ve Standartlaşma: Manuel ölçümlerdeki operatör öznelliği, yorgunluk faktörü, hava koşullarının etkisi ve farklı ekiplerin farklı ölçüm standartları veya cihaz kalibrasyonları kullanması, veri setlerinde tutarsızlıklara ve kümülatif hata payının artmasına yol açmaktadır.

- Erişilebilirlik ve İş Güvenliği: Sarp araziler, yüksek irtifadaki buzul gölleri, mayınlı sınır bölgeleri veya koruma altındaki hassas ekosistemlerde fiziksel ölçüm yapmak çoğu zaman lojistik olarak imkansız veya personel güvenliği açısından kabul edilemez riskler barındırmaktadır.

Bu kısıtlar, su kaynaklarının havza bazında bütüncül ve etkin yönetimini zorlaştırmakta, kuraklık, taşkın veya su kirliliği gibi kriz anlarında karar vericilerin hızlı aksiyon almasını engelleyen ciddi bir veri körlüğü yaratmaktadır.

1.2. Uzaktan Algılamanın Rolü

Günümüzde su kaynaklarının yönetimi ve korunması, iklim değişikliği ve hızlı şehirleşme gibi faktörler nedeniyle stratejik bir önem kazanmıştır. Bu kaynakların izlenmesinde geleneksel saha çalışmaları; yüksek maliyet, lojistik zorluklar ve sınırlı örnekleme alanları gibi dezavantajlar barındırmaktadır. Uzaktan algılama teknolojileri, yeryüzünün geniş coğrafi alanlarını elektromanyetik spektrumun farklı bantları aracılığıyla ve belirli periyotlarla görüntüleyerek bu kısıtlamalara karşı yenilikçi ve sürdürülebilir bir çözüm sunmaktadır. Uydu tabanlı gözlemler, yersel yöntemlerle elde edilmesi mümkün olmayan "bütüncül bakış açısını" sağlayarak, su kütlelerinin zamansal ve mekânsal değişimlerinin yüksek doğrulukla analiz edilmesine olanak tanır.

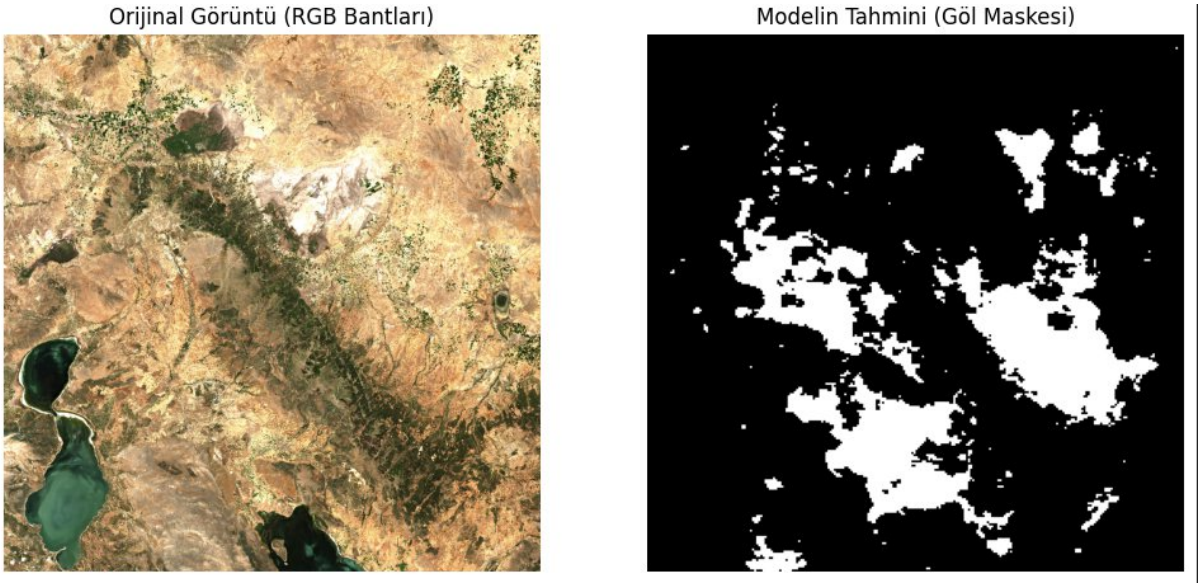
Bu süreçte, Avrupa Uzay Ajansı tarafından Copernicus programı kapsamında geliştirilen Sentinel-2 uydu takımı, su kaynaklarının takibinde devrim niteliğinde bir veri kaynağı haline gelmiştir. Sentinel-2'nin sunduğu 10 metreye kadar ulaşan yüksek uzamsal çözünürlük, küçük ölçekli göletlerin ve kıyı şeritlerinin dahi hassas bir şekilde tanımlanmasını sağlar. Bunun yanı sıra, uydunun yaklaşık 5 günlük kısa yeniden ziyaret süresi (zamansal çözünürlük), su seviyelerindeki mevsimsel değişimlerin ve ani su baskını gibi dinamik olayların gerçek zamanlıya yakın bir performansla izlenmesine imkan tanır. Sentinel-2 uydusunun sahip olduğu çok bantlı radyometre, suyun spektral imzasını kara yapılarından ayırt etmede ve su kalitesi parametrelerinin kestiriminde kritik bir rol oynamaktadır.

Fiziksel olarak ulaşılması zor, tehlikeli veya çok geniş arazilerde bulunan su kütleleri, uydu sistemleri sayesinde sürekli bir denetim mekanizmasına dahil edilebilmektedir. Manuel kontrol süreçlerinde insan faktöründen kaynaklanan hata payı, subjektif değerlendirmeler ve operasyonel maliyetler; uzaktan algılama verilerinin otomatize edilmesi ve derin öğrenme tabanlı segmentasyon algoritmalarıyla birleştirilmesi sayesinde minimize edilmektedir. Sonuç olarak,

uzaktan algılama teknolojileri sadece bir veri toplama aracı değil, aynı zamanda su kaynaklarının korunmasına yönelik karar destek sistemlerinin en temel ve objektif yapı taşıdır.

1.3. Mevcut Yöntemlerin Kısıtları ve Makine Öğrenmesi İhtiyacı

Su kütlelerinin otomatik olarak belirlenmesinde literatürde uzun yıllardır spektral indeks tabanlı yöntemler kullanılmıştır. Bu yöntemlerin başında gelen Normalize Edilmiş Fark Su İndeksi, suyun yeşil banttaki yüksek yansıması ile yakın kızılötesi banttaki yüksek emilimi arasındaki farkı kullanarak bir oranlama yapar. Ancak bu tür matematiksel indekslerin başarısı, su ve kara ayrımını yapacak olan "eşik değerinin" doğru seçilmesine doğrudan bağlıdır. Sabit bir eşik değeri kullanımı; atmosferik koşullar, güneşin geliş açısı, suyun içindeki tortu miktarı (bulanıklık) ve mevsimsel bitki örtüsü değişimleri nedeniyle çoğu zaman hatalı sonuçlar vermektedir. Özellikle topografik gölgelerin, karlı dağların veya kentsel alanlardaki koyu renkli yüzeylerin spektral imzası su ile karıştırılabilmekte, bu da düşük doğruluk oranlarına yol açmaktadır.



Şekil 1.2. NDWI Test Görüntüsü

Geleneksel indekslerin bu kısıtlarını aşmak amacıyla, son yıllarda bilgisayarlı görü alanındaki gelişmelerle birlikte Derin Öğrenme tabanlı yaklaşımlar ön plana çıkmıştır. Özellikle Evrişimli Sinir Ağları, sadece piksel bazlı renk değerlerine odaklanmak yerine, görüntüdeki doku, biçim ve bağlamsal bilgileri de öğrenme kapasitesine sahiptir. Şekil 1.2'de görüldüğü üzere, orijinal RGB görüntüsünde arazinin karmaşık ve heterojen yapısı, su kütlelerinin manuel veya basit eşikleme yöntemleriyle ayrıştırılmasını oldukça güçleştirmektedir. Ancak derin öğrenme

modeli, bu zorlu koşullara rağmen sağ taraftaki tahmin maskesinde görüldüğü gibi, su alanlarını keskin ve doğru sınırlarla segmentize edebilmektedir.

Bu çalışmada, manuel özellik çıkarımı süreçlerini ortadan kaldıran ve doğrudan ham uydu verisinden hiyerarşik özellikler öğrenen bir mimari tercih edilmiştir. Böylece Türkiye coğrafyasının sunduğu sığ sular, mevsimsel kuruyan göller ve dağlık arazilerdeki gölge karmaşası gibi zorlu senaryolarda, geleneksel NDWI yönteminin ötesine geçen, yüksek doğruluklu bir su sınıflandırma sistemi tasarlanmıştır. Bu sistem, insan hatasından arındırılmış ve operasyonel maliyeti düşük bir karar destek mekanizması sunarak su kaynaklarının sürdürülebilir yönetimine katkı sağlamaktadır.

1.4. Çalışmanın Amacı

Bu tezin temel amacı, Sentinel-2 uydu görüntülerini birincil veri kaynağı olarak kullanarak, belirlenen coğrafi koordinatlardaki göl ve su kütlelerinin tespitini sağlayan, yüksek doğruluk oranına sahip, derin öğrenme tabanlı bir anlamsal sınıflandırma modeli geliştirmektir. Çalışma, sadece teorik bir modelleme süreci değil, aynı zamanda veriden son kullanıcı arayüzüne kadar uzanan uçtan uca entegre bir sistem tasarımı olarak kurgulanmıştır.

Çalışma kapsamında ele alınan öncelikli hedefler ve çalışmanın özgün değerleri aşağıda detaylandırılmıştır:

- **Özgün Veri Setinin Sıfırdan Oluşturulması:** Literatürde yaygın olarak kullanılan hazır uydu veri setlerinin (örneğin DeepGlobe, ISPRS vb.), Türkiye coğrafyasının kendine has spektral ve kimyasal karakteristiklerini (yüksek tuzluluk, değişken mineral yapıları, farklı bitki örtüsü dokuları) temsil etmekte yetersiz kaldığı tespit edilmiştir. Bu uyumsuzluk problemini ortadan kaldırmak amacıyla, literatürdeki hazır veri setleri kullanılmamış; bunun yerine Türkiye'nin farklı bölgelerinden, çeşitli iklim ve topoğrafya özelliklerini yansıtan Sentinel-2 görüntüleri toplanarak, bu tez çalışmasına özel, tamamen özgün bir veri seti sıfırdan oluşturulmuştur.
- **Spektral Bant Optimizasyonu:** Standart görünür ışık bantlarının (RGB - Kırmızı, Yeşil, Mavi) su sınıflandırmasında tek başına yeterli olmadığı deneysel analizlerle ortaya konulmuştur (Şekil 1.2). Görünür ışık spektrumunda suyun, gölge ve koyu renkli yüzeylerle karıştırılma ihtimaline karşı, suyun yüksek oranda emilim gösterdiği Kısa Dalga Kızılötesi (SWIR) bantları modele entegre edilmiştir. Bu sayede, modelin ayırt edici gücü artırılarak daha hassas segmentasyon sonuçları elde edilmiştir.
- **Erişilebilir Karar Destek Sistemi:** Geliştirilen karmaşık derin öğrenme modelinin, teknik bilgi seviyesi ne olursa olsun son kullanıcılar (çevre mühendisleri, su yönetimi

uzmanları vb.) tarafından kolaylıkla kullanılabilmesi hedeflenmiştir. Bu doğrultuda, modelin çıktılarının görselleştirilmesine, koordinat bazlı sorgulama yapılmasına ve değişim analizlerinin raporlanmasına olanak tanıyan kullanıcı dostu bir masaüstü arayüzü tasarlanmıştır.

Sonuç olarak bu çalışma, Türkiye'nin su kaynaklarının periyodik takibini otomatize ederek, hem bilimsel literatüre yerel dinamiklerle uyumlu özgün bir veri seti ve metodoloji kazandırmayı, hem de pratik uygulamada karar vericilere güvenilir bir araç sunmayı amaçlamaktadır.

2. GENEL BİLGİLER

2.1. Uzaktan Algılama

Uzaktan algılama, temel bir disiplin olarak, incelenen yeryüzü nesneleri, alanlar veya fenomenlerle doğrudan fiziksel bir temas kurmaksızın bilgi edinme bilimi ve sanatı olarak tanımlanmaktadır. Bu süreç; uydular, uçaklar ve son yıllarda teknolojik ivme kazanan İnsansız Hava Araçları gibi platformlar üzerine yerleştirilmiş hassas sensörler (radyometreler, tarayıcılar vb.) aracılığıyla gerçekleştirilir. Uzaktan algılamanın çalışma prensibi, nesnelerin elektromanyetik enerjiyi yansıtma, emme veya yayma karakteristiklerindeki farklılıklara dayanarak, bu verilerin kaydedilmesi ve ardından fiziksel veya dijital yöntemlerle analiz edilmesidir.

Bu teknoloji, elektromanyetik spektrumun sunduğu geniş olanaklardan faydalanır. Sadece insan gözünün algılayabildiği "Görünür Bölge" (Kırmızı, Yeşil, Mavi) bantlarıyla sınırlı kalmayıp; spektrumun görünür bölge ötesindeki kızılötesi, morötesi ve mikrodalga gibi bantlarını da aktif olarak kullanır. Özellikle su kaynaklarının analizinde, kızılötesi bantların kullanımı, suyun spektral yansımasının kara yüzeylerinden keskin bir şekilde ayrılmasını sağladığı için kritik bir öneme sahiptir.

Uzaktan algılama sistemlerinin en büyük avantajı, geniş coğrafi alanların eş zamanlı olarak görüntülenmesine ve periyodik veriler toplanmasına imkan tanımasıdır. Geleneksel yerinde ölçüm yöntemlerinin (saha çalışmaları) getirdiği yüksek operasyonel maliyetleri, lojistik zorlukları ve zaman kaybını minimize ederek; mümkün olan en düşük maliyetle, bilimsel ve operasyonel kararlar için ihtiyaç duyulan "maksimum veri derinliğini" sunmayı amaçlar. Bu yönüyle modern uzaktan algılama, yer bilimleri ve çevresel izleme çalışmalarının vazgeçilmez bir yapı taşı haline gelmiştir.

2.1.1. Tarihçe ve Gelişim

Uzaktan algılama teknolojisinin tarihsel serüveni, 19. yüzyılın ortalarında Gaspard-Félix Tournachon tarafından Paris üzerinde balonla çekilen ilk hava fotoğrafları ile başlamış ve günümüze kadar baş döndürücü bir hızla ilerlemiştir. Başlangıçta yalnızca görsel bir kayıt aracı olarak görülen bu teknoloji, I. ve II. Dünya Savaşları sırasında hava keşiflerinin stratejik önem kazanmasıyla birlikte sistematik bir veri toplama yöntemine dönüşmüştür.

Teknolojinin asıl kırılma noktası, Soğuk Savaş dönemiyle birlikte başlayan "Uzay Çağı" olmuştur. Bu dönemde süper güçler tarafından geliştirilen ve başlangıçta tamamen askeri istihbarat ve gözetleme amaçlı kullanılan (örneğin Corona ve Zenit programları) uydu sistemleri, yörüngeden yeryüzünü izlemenin teknik altyapısını oluşturmuştur. Ancak uzaktan algılamanın bilimsel ve sivil bir disiplin olarak kimlik kazanması, 1972 yılında NASA tarafından fırlatılan ilk yeryüzü kaynakları gözlem uydusu ERTS-1 (sonradan adıyla Landsat-1) ile gerçekleşmiştir. Bu adım, uzaydan elde edilen verilerin sadece askeri değil; tarım, jeoloji ve haritacılık gibi sivil alanlarda da kullanılabileceğini kanıtlayan bir dönüm noktasıdır.

Günümüzde ise uzaktan algılama, sadece optik kameralarla sınırlı kalmayıp, radar, Lidar ve hiperspektral sensörler gibi çok katmanlı ve gelişmiş görüntüleme teknolojilerini barındıran devasa bir ekosisteme evrilmiştir. Avrupa Uzay Ajansı'nın Copernicus programı ve Sentinel uydu takımları gibi girişimler sayesinde, veriye erişim demokratikleşmiş ve küresel ölçekte standartlaşmıştır. Geçmişin "izleme" odaklı yaklaşımı, bugün yerini büyük veri analitiği ve yapay zeka ile desteklenen; tarımsal rekolte tahminlerinden afet sonrası hasar tespitine, şehir planlamadan iklim değişikliği modellemelerine kadar uzanan geniş bir yelpazede "karar destek mekanizmasına" bırakmıştır.

2.1.2. Elektromanyetik Spektrum ve Algılama Mantığı

Cisimler, Güneşten gelen ışığı farklı dalga boylarında farklı oranlarda yansıtır veya soğurur. Bu karakteristik yansıma eğrisi "spektral imza" olarak adlandırılır. Su, görünür bölgedeki ışığı belirli oranlarda yansıtırken, kızılötesi dalga boylarını büyük ölçüde soğurur.



Şekil 2.1. Salda Gölü RGB Ve IR

Bitki örtüsü ise tam tersine Yakın Kızılötesi bölgesinde yüksek yansıma yapar. Uzaktan algılama sensörleri bu farkları kullanarak maddeleri ayırt eder.

2.1.3. Aktif ve Pasif Sensörler

Pasif Sensörler: Güneş ışığı gibi doğal kaynaklardan gelen ve nesnelerden yansıyan ışıktan bilgi elde ederler; kendi enerjilerini üretmezler (Örneğin: Sentinel-2 uydusunun RGB ve Kızılötesi bantları).

Aktif Sensörler: Kendi ürettikleri enerji dalgalarını hedefe gönderip, geri yansıyan sinyalleri ölçerek veri elde ederler (Örneğin: Radar, LiDAR ve Sentinel-1 uydusu gibi sistemler).

2.2. Sentinel-2 Uydu Misyonu

Avrupa Komisyonu ve Avrupa Uzay Ajansı'nın beraber yürüttüğü Copernicus programının bir ürünü olan Sentinel-2, yeryüzünü 60m 20m ve 10m formatlarında izlememizi sağlayan bir optik uydu sistemidir. Aslında bu misyon tek bir uydudan değil, aynı yörünge üzerinde birbirine tam zıt (180 derece) konumlandırılmış Sentinel-2A ve Sentinel-2B adlı ikiz uydulardan oluşur.

Uyduların bu stratejik yerleşimi, Dünyanın herhangi bir noktasının üzerinden geçme sıklığını (tekrar ziyaret süresini) ekvatorda 5 güne, orta enlemlerde ise 2-3 güne kadar düşürür. Bu sayede yeryüzündeki hızlı değişimleri dinamik bir şekilde takip etmek mümkün olur. Sentinel-2'nin merkezinde ise Çok Spektral Enstrüman yer alır. Bu sensör, sadece insan gözünün gördüğü renkleri değil; su kaynakları ve bitki örtüsünü analiz etmek için hayati öneme sahip kızılötesi bantları da yakalar. Tüm bu özellikleriyle Sentinel-2; tarımdan afet yönetimine kadar pek çok alanda araştırmacılara ücretsiz ve açık kaynaklı veri sunan önemli ve verimli bir kaynaktır.

2.2.1. MultiSpectral Instrument (MSI)

Sentinel-2 uydusu üzerindeki MSI sensörü, farklı dalga boylarında 13 spektral bantta görüntü alır. Bu bantlar, uzamsal çözünürlüklerine göre üç gruba ayrılır:

- **10 metre çözünürlük:** B2 (Mavi), B3 (Yeşil), B4 (Kırmızı), B8 (NIR).
- **20 metre çözünürlük:** B5, B6, B7 (Red Edge), B8A, B11, B12 (SWIR).
- **60 metre çözünürlük:** B1 (Aerosol), B9 (Su buharı), B10 (Cirrus - Bulut).

2.2.2. SWIR (kısa dalga kızılötesi) bandı

Bu çalışmada kritik rol oynayan Band 11 (SWIR- 1610 nm), 20 metre çözünürlüktedir. SWIR bandı; suyun ışığı soğurması (siyah görünmesi) ve kar, buz veya bulut gibi diğer su içerikli yüzeylerin ışığı yansıtması (parlak görünmesi) nedeniyle, su tespitinde RGB bantlarına göre daha ayırt edicidir. Bu sayede, RGB görüntülerde dağlık alanlar veya parlak yüzeylerin su ile karıştırılması sorunu yaşanırken, Band 11'de bu durum gözlenmez; dağlık alanlar parlak (beyaz) görünmeye devam ederken, su kütleleri siyah görünerek net bir şekilde ayrışmaktadır.

2.2.3. Makine Öğrenmesi

Makine Öğrenmesi, bilgisayarların her bir görevi yerine getirmesi için açıkça programlanmasına gerek kalmadan, veriler üzerinden deneyim kazanarak öğrenmesini sağlayan yapay zekanın bir alt dalıdır. Geleneksel yazılım anlayışında, bir problemin çözümü için bilgisayara adım adım ne yapması gerektiği kodlanırken; makine öğrenmesinde sisteme büyük miktarda veri sunulur ve sistem bu verilerdeki gizli örüntüleri ve ilişkileri kendi kendine keşfeder. Tıpkı bir insanın tecrübelerinden ders çıkarması gibi, algoritmalar da işledikleri veri arttıkça performanslarını iyileştirerek daha isabetli tahminler ve kararlar üretir hale gelirler.

2.2.4. Yapay Sinir Ağları Temelleri

Biyolojik sinir sisteminden ilham alınarak geliştirilen yapay sinir ağlarının en küçük yapı taşı Perceptron'dur. Temel çalışma prensibi oldukça sadedir; sisteme giren veriler belirli ağırlık değerleriyle çarpılarak toplanır ve bir aktivasyon fonksiyonundan (örneğin ReLU veya Sigmoid) geçirilerek bir çıktı üretilir. Buradaki "öğrenme" dediğimiz süreç, aslında ağın tahmin ettiği sonuç ile gerçek sonuç arasındaki hatayı en aza indirmek için bu ağırlık değerlerinin sürekli güncellenmesinden ibarettir.

2.2.5. Backpropagation (Geri Yayılım) Algoritması

Ağın öğrenmesini sağlayan matematiksel motor, geri yayılım algoritmasıdır. Model bir tahmin yaptığında ortaya çıkan hata, türev zincir kuralı kullanılarak ağın sonundan başına doğru geri gönderilir. Bu işlem sırasında, hataya en çok sebep olan bağlantıların ağırlıkları daha fazla değiştirilir. Yani algoritma, her bir nörona "bir dahaki sefere daha doğru sonuç vermek için kendini ne kadar düzeltmesi gerektiğini" matematiksel olarak söyler.

2.3. Evrişimli Sinir Ağları (CNN)

Standart yapay sinir ağları, görüntü gibi karmaşık ve boyutlu verileri işlemekte yetersiz kalır. İşte bu noktada, görüntü verilerini işlemek için özelleşmiş Evrişimli Sinir Ağları devreye girer. CNN'ler, pikselleri düz bir liste olarak değil, bir bütün halinde işler. Bu sayede resimdeki bir nesnenin şeklini, dokusunu ve uzamsal ilişkilerini kaybetmeden öğrenmeyi başarır.

2.3.1. Konvolüsyon Katmanı

CNN mimarisinin kalbi sayılan bu katman, görüntünün özelliklerini çıkaran kısımdır. Görüntü üzerinde dolaşan küçük filtreler, resimdeki dikey-yatay çizgileri, köşeleri veya renk geçişlerini tarar. Matematiksel olarak bu işlem, filtre matrisi ile görüntü matrisinin nokta çarpımıdır.

2.3.2. Havuzlama Katmanı

Konvolüsyonel Sinir Ağları mimarisinde, evrişim işleminin hemen ardından genellikle **Havuzlama** katmanı gelir. Konvolüsyon katmanından elde edilen öznitelik haritaları, görüntüdeki her bir detayı piksel piksel barındırdığı için genellikle yüksek boyutludur. Bu durum, hem hesaplama maliyetini artırır hem de ağın gereksiz detayları ezberlemesine (overfitting) yol açabilir. Havuzlama katmanı, bu veriyi stratejik bir şekilde özetleyerek boyutunu küçültmek amacıyla kullanılır.

Bu katmanın temel işlevleri ve çalışma prensipleri şunlardır:

I. Boyut İndirgeme ve Hesaplama Maliyeti

Havuzlama işlemi, giriş görüntüsü veya öznitelik haritası üzerinde belirli bir filtre (genellikle 2x2 boyutunda) gezdirerek çalışır. Bu işlem, ağdaki parametre sayısını ve dolayısıyla gereken işlem gücünü ciddi oranda düşürür. Örneğin, 2x2 boyutunda ve 2 adımlık bir havuzlama işlemi, verinin genişliğini ve yüksekliğini yarıya indirerek toplam veri boyutunu %75 oranında küçültür. Bu sayede model daha hızlı eğitilebilir ve daha az bellek tüketir.

II. Maksimum Ortaklama Yöntemi

Havuzlama işlemleri arasında en yaygın kullanılan teknik **Max Pooling** yöntemidir. Bu yöntemde, filtre kapsamındaki bölgedeki pikseller incelenir ve sadece matematiksel değeri en yüksek olan değer seçilerek yeni katmana aktarılır; geri kalan değerler atılır.

III. **Neden En Büyük Değer?** Bir öznitelik haritasındaki yüksek değerler, o bölgede aranan özelliğin (örneğin dikey bir çizgi, bir göz bebeği veya keskin bir köşe) varlığının güçlü olduğunu gösterir. Max Pooling, "Burada önemli bir özellik var" diyerek sadece bu güçlü sinyali tutar ve arka plandaki zayıf bilgileri eler.

IV. **Değişmezlik ve Gürültü Filtreleme**

Havuzlama katmanının modele sağladığı en büyük katkılardan biri "Öteleme Değişmezliği" yeteneğidir. Bir görüntüdeki nesne (örneğin bir kedi) sağa veya sola birkaç piksel kaysa bile, Max Pooling işlemi o bölgedeki en yüksek değeri yine yakalayacağı için sonuç değişmez.

V. **Gürültüye Dayanıklılık:** Görüntüdeki küçük bozulmalar, titremeler veya gereksiz detaylar, havuzlama sırasında elenen düşük değerli pikseller arasında kalır. Böylece model, görüntünün gürültüsünden ziyade temel yapısal özelliklerine odaklanmayı öğrenir.

Özetle, havuzlama katmanı sadece veriyi küçültmekle kalmaz; aynı zamanda modelin işlem yükünü hafifletir, aşırı öğrenmeyi engellemeye yardımcı olur ve modelin nesneleri konumlarından bağımsız olarak tanımasına olanak tanır.

2.4. Semantik Segmentasyon

Bilgisayarlı görü alanında, bir görüntünün analiz edilmesi hiyerarşik bir karmaşıklık düzeyine sahiptir. En temel seviyede "Görüntü Sınıflandırma", resimde ne olduğunu (örneğin "Göl") belirlerken; "Nesne Tespiti" nesnenin yerini dikdörtgen bir kutu ile işaretler. Ancak su kaynaklarının yüzey alanı değişimi, kıyı şeridi analizi veya taşkın tespiti gibi hassas mühendislik problemlerinde, nesnenin sadece "nerede" olduğunu bilmek yeterli değildir; nesnenin "tam sınırlarını" ve geometrisini bilmek gerekir. İşte bu ihtiyacı karşılayan en gelişmiş teknik, **Semantik Segmentasyon** yöntemidir.

Semantik segmentasyon, dijital bir görüntüyü oluşturan her bir pikselin, önceden belirlenmiş bir sınıf etiketiyle ilişkilendirildiği "piksel tabanlı yoğun tahmin" işlemidir. Klasik sınıflandırma algoritmaları görüntünün bütününe tek bir etiket atarken, semantik segmentasyon görüntüyü piksel düzeyinde ayrıştırır. Sonuç olarak elde edilen çıktı, orijinal giriş görüntüsüyle aynı uzamsal boyutlara (genişlik x yükseklik) sahip, ancak her pikselin ait olduğu sınıfın sayısal değerini taşıdığı bir "segmentasyon haritası" veya "maske"dir.

Bu tez çalışmasında ele alınan su tespiti problemi, literatürde **İkili Semantik Segmentasyon** olarak sınıflandırılmaktadır. Modelin amacı, Sentinel-2 uydu görüntüsündeki milyonlarca pikseli analiz ederek, her bir piksel için şu kararı vermektir: "Bu piksel su sınıfına mı aittir (1), yoksa arka plan/su dışı sınıfa mı aittir (0)?". Bu yaklaşım sayesinde, sadece gölün varlığı değil; gölün şekli, kıyı girintileri ve adacıklar gibi morfolojik özellikleri de yüksek doğrulukla dijitalleştirilebilmektedir.

3. MATERYAL VE YÖNTEM

Bu bölüm, tezin en özgün ve teknik detaylarını içermektedir. Proje geliştirme sürecinde karşılaşılan zorluklar, "deneme-yanılma" süreçleri ve nihai çözüm mimarisi detaylandırılmıştır.

3.1. Veri Seti Oluşturma Süreci ve Karşılaşılan Zorluklar

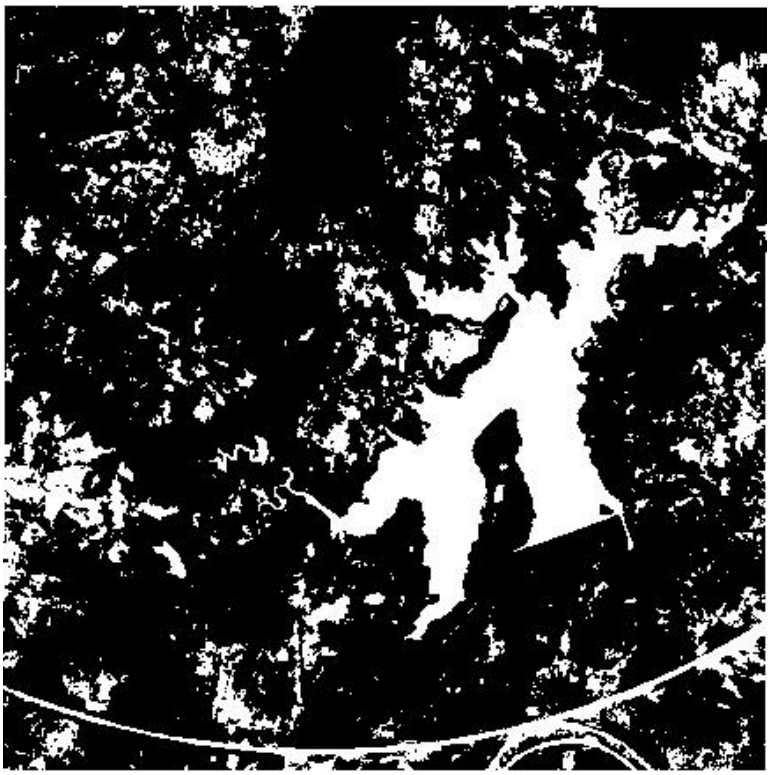
Model eğitiminin performansı, büyük ölçüde oluşturulan veri setinin doğruluğuna ve yapısına bağlıdır. Bu bölümde, çalışmamız kapsamında en uygun veri setine ulaşmak için izlenen yöntemler ele alınmıştır. Başlangıçta karşılaşılan format ve içerik sorunları, denenen farklı veri kaynakları ve Türkiye coğrafyasına özgü nihai veri setinin hazırlanış süreci sırasıyla açıklanmıştır.

3.1.1. Başlangıç Hatası: RGB ve JPEG Kullanımı

Projenin ilk aşamalarında, Google Earth ve benzeri kaynaklardan elde edilen standart RGB (Kırmızı-Yeşil-Mavi) formatındaki JPEG görüntüler ile model eğitimi denedik. Ancak yaptığımız testlerde modelin, suyun fiziksel özelliklerini değil, sadece "koyu renkli alanları" öğrendiğini gözlemledik.



Şekil 3.1. Bir jpeg görüntünün maskesiz hali



Şekil 3.2. Bir jpeg görüntünün maskeli hali

Sorun: Geliştirilen model, dağ gölgesini ve bina çatıları gibi alanları su olarak yanlış sınıflandırdı (False Positive).

Analiz: RGB bantları, insan gözüne hitap etmek için sıkıştırılmış verilerdir ve suyun elektromanyetik spektrumdaki ayırt edici özelliklerini (özellikle IR bölgesindeki soğurmayı) taşımazlar.

3.1.2. Hazır Veri Seti Deneyimi (Polonya Gölleri)

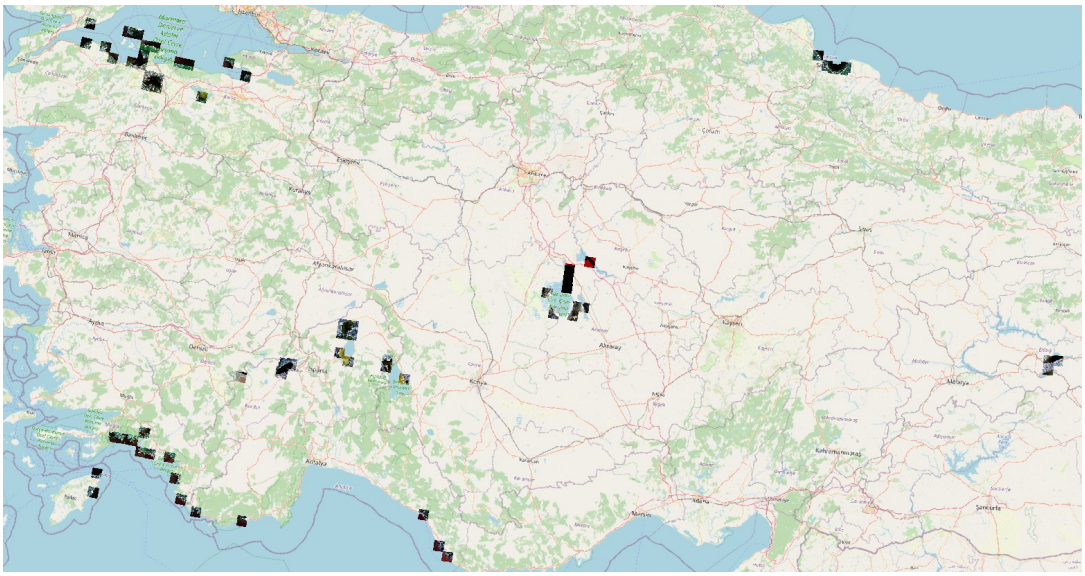
Veri seti eksikliğini gidermek için Kaggle platformunda bulunan "Polonya Gölleri" veri seti inceledik. Ancak bu veri setinde bantlar önceden birleştirilmiş halde sunulduğu için, modelin hangi bantlarla eğitileceğine müdahale edemedik. Ayrıca Polonya'nın bitki örtüsü ve göl yapısı ile Türkiye'nin coğrafi yapısı (kurak alanlar, karlı dağlar) arasındaki farklar, modelimizin yerel verilerde başarısız olmasına neden oldu.

3.1.3. Nihai Çözüm: Ham TIFF Formatı ve SWIR Bandı Entegrasyonu

Yukarıdaki sorunları aşmak için ham uydu verilerini kullanmaya karar verdik. JPEG yerine, sıkıştırmasız ve çok kanallı veri saklayabilen **GeoTIFF** formatı tercih ettik.

- **Band 11 (SWIR) Kullanımı:** Literatür taraması sonucunda, suyun tespiti için en kritik bandın kısa dalga kızılötesi olduğu belirlenmiştir. Bu bantta su ışığı neredeyse tamamen soğurarak siyah, kar ve bulutlar ise parlak görünür. Bu sayede önceden dağlar yüzünden elde ettiğimiz bozuk sonuçların oluşmasını engellendi.
- **Özgün Veri Seti:** Türkiye genelinden, farklı iklim ve coğrafi özelliklere sahip (Van Gölü, Tuz Gölü, Beyşehir Gölü vb.) irili ufaklı toplam **69 adet göl** seçildi. Her bir gölün geojson verisi elle oluşturuldu.
- **Bulut Filtreleme:** SWIR bandı su tespitinde oldukça başarılı olsa da bulutlar bu bantta da parlak göründüğü için zaman zaman yanıltıcı olabiliyor. Bu engeli aşmak adına, veri indirme aşamasında Sentinel-2'nin bulut filtresinden yararlandık ve analiz sürecine sadece temiz, bulutsuz görüntülerin dahil edilmesini sağladık.

Oluşturulan özgün veri seti, Türkiye'nin farklı iklim bölgelerini temsil eden 69 farklı gölü kapsamaktadır. Bu göllerin seçiminde hem yüzey alanı büyüklüğü hem de mevsimsel su seviyesi değişimleri dikkate alınmıştır. Şekil 3.1'de çalışma alanında kullanılan göllerin Türkiye haritası üzerindeki konumsal dağılımları verilmektedir.



Şekil 3.3. Göllerin Türkiye Haritası Üzerindeki Dağılımı

3.2. Teknik Altyapı ve Kütüphaneler

Projenin geliştirme sürecinde, sunduğu geniş kütüphane desteği ve veri bilimi alanındaki piyasa kabulü nedeniyle Python dili tercih edilmiştir. Kullandığımız temel bileşenler ve projeye katkıları şunlardır:

- **PyTorch:** U-Net mimarisini hayata geçirirken, sunduğu esneklik ve dinamik yapı nedeniyle PyTorch kütüphanesi temel alındı. Özellikle GPU üzerinde paralel işlem yapabilme yeteneği, modelin eğitim sürecinin yönetimini kolaylaştırdı.
- **Rasterio:** Standart görüntü işleme kütüphaneleri coğrafi verileri okuyamaz. Bu eksikliği gidermek ve çok bantlı GeoTIFF dosyalarını, coğrafi özelliklerini kaybetmeden işleyebilmek için Rasterio kütüphanesi kullanılmıştır.
- **NumPy:** Uydu görüntüleri aslında devasa sayısal matrislerdir. Bu matrisler üzerindeki çarpma ve manipülasyon işlemlerini yüksek performansla gerçekleştirmek için NumPy kütüphanesi projenin bel kemiğini oluşturdu.
- **OpenCV:** Görüntülerin ön işlenmesi ve temel matris operasyonlarında endüstri standardı olan bu kütüphane kullanılmıştır.
- **CUDA & Donanım Hızlandırma:** Binlerce uydu görüntüsünü işlemci (CPU) ile eğitmek haftalar sürebilirdi. Bu süreyi optimize etmek adına NVIDIA'nın **CUDA** mimarisini kullanarak eğitim yükü ekran kartına (GPU) aktarılmıştır ve "Mixed Precision Training" tekniğiyle süreç hızlandırılmıştır.

3.3. Veri Ön Süreci

Ham uydu verilerinin derin öğrenme modelleri tarafından işlenebilir hale getirilmesi, modelin öğrenme performansını ve doğruluğunu doğrudan etkileyen en kritik aşamalardan biridir. Sentinel-2 uydusundan elde edilen çok spektral veriler, doğrudan model eğitimine uygun olmadığı için bir dizi ön işlemden geçirilmelidir. Bu bölümde; model mimarisine uygun girdiyi oluşturmak amacıyla uygulanan kanal birleştirme teknikleri, veri tutarlılığını sağlamak için yapılan uzamsal çözünürlük optimizasyonları ve eğitim setinin kalitesini artıran maskeleme süreçleri detaylandırılmıştır.

3.3.1. Kanal Birleştirme

Modelimizin girdi mimarisi, standart 3 kanallı (RGB) görüntülerin sınırlarını aşarak, projeye özel 4 kanallı birleşik bir yapı üzerine kurulmuştur. Bu yapıyı oluşturmak adına Sentinel-2'nin görünür ışık bantları olan Kırmızı (B04), Yeşil (B03) ve Mavi (B02)'ye ek olarak, suyun ayırt edici spektral imzasını taşıyan SWIR (B11) bandı sisteme dahil edilmiştir.

Bu dört farklı spektral bant, geliştirilen birleştirici.py isimli Python betiği aracılığıyla üst üste katmanlayarak analiz için tek parça ve işlenebilir bir .tif dosyasına dönüştürülmüştür. Veri

ön işleme sürecinin bu kritik adımında kullanılan kanal birleştirme kod görseli aşağıda gösterilmiştir:

```
bands_order = ['B02', 'B03', 'B04', 'B11']

for header in sorted(headers):
    src_files = []
    for band in bands_order:
        file_path = outputs_dir / f"{header}_{band}_20m.jp2"
        if file_path.exists():
            src_files.append(str(file_path))

    if len(src_files) == 4:
        print(f"Merging bands for {header}")
        output_path = merged_dir / f"{header}_merged.tif"
        cmd = ['gdal_merge.py', '-separate', '-o', str(output_path)] + src_files
        result = subprocess.run(cmd, capture_output=True, text=True)
        if result.returncode == 0:
            print(f"Saved {output_path}")
        else:
            print(f"Error merging {header}: {result.stderr}")
    else:
        print(f"Skipping {header}: missing {4 - len(src_files)} bands")
```

Şekil 3.4. Kanal birleştirme kodu

3.3.2. Uzamsal Çözünürlük ve Veri Tutarlılığı

Sentinel-2 uydusu, bant türüne göre farklı çözünürlüklerde (10m, 20m ve 60m) veri sağlıyor olsa da kullanılan U-Net mimarisi teknik olarak tüm giriş verilerinin aynı boyutta olmasını bekler.

Projenin merkezini oluşturan su tespiti işleminde, en önemli veri kaynağı olan SWIR bandı (Band 11) uydu tarafından verilen kaynağa göre 20 metre çözünürlüktedir. Bu noktada verinin özgünlüğünü bozacak yapay büyütme veya küçültme işlemleriyle veriyi riske atmak yerine, projenin standart çözünürlüğünü 20 metre olarak belirlendi. Verileri temin ederken RGB bantlarını da doğrudan bu çözünürlükte (20m versiyonlarıyla) alarak hem daha optimize bir program hem de veri setinde en doğal haliyle boyutsal uyum sağlandı.

3.3.3. Etiketleme ve İnsan Faktörü

Bu çalışmada özgün veri setinin hazırlanması, statik bir veri toplama işleminden ziyade, projenin ihtiyaçlarına göre şekillenen dinamik ve iteratif bir süreç olarak yürütülmüştür. Başlangıç aşamasında açık kaynak kodlu Coğrafi Bilgi Sistemleri (CBS) yazılımı olan QGIS;

yalnızca JPG formatındaki uydu görüntülerinin görsel kontrolü ve Kaggle gibi platformlardaki mevcut veri setlerinin incelenmesi amacıyla ikincil bir araç olarak konumlandırılmıştı. Ancak çalışmanın ilerleyen safhalarında, QGIS yazılımı, projenin "referans yer gerçeği" (ground truth) verisinin oluşturulmasında merkezi bir rol üstlenmiştir.

Sentinel-2 ham verileriyle birlikte gelen veya basit spektral indekslerle (NDWI vb.) otomatik olarak üretilen su maskelerinin, özellikle kıyı şeritlerinde, gölgeli alanlarda ve sığ sularda yüksek hata oranlarına sahip olduğu tespit edilmiştir. Otomatik algoritmaların ürettiği bu maskelerin "doğru kabul edilerek" modele verilmesi, literatürde "Çöp Giren Çöp Çıkar" (Garbage In, Garbage Out) olarak bilinen probleme yol açarak modelin yanlış özellikleri öğrenmesine neden olmaktadır.

Bu riski elimine etmek adına, veri hazırlama sürecine "insan faktörü" (Human-in-the-loop) aktif olarak dahil edilmiştir. Türkiye coğrafyasından elde edilen binlerce uydu görüntüsü, QGIS ortamında uzman görüşüyle tek tek incelenmiştir. Hatalı çizilen göl sınırları, su sanılan koyu renkli tarım arazileri veya bulut gölgeleri bizzat manuel yöntemlerle düzeltilmiştir. Bu titiz manuel temizlik ve etiketleme süreci; modelin gürültülü (noisy) veriden arındırılmasını sağlamış ve eğitimin, gerçeği birebir yansıtan yüksek kaliteli veriler üzerinden gerçekleştirilmesini garanti altına almıştır.

3.3.4. Maske Oluşturma ve Etiketleme

Uydu görüntüleri orijinalinde 16-bit derinliğe (0-65535 arası değerlere) sahiptir. Ancak projedeki temel amaç "su var mı, yok mu?" sorusuna cevap vermek olduğu için, bu verileri 1-bitlik (0 veya 1) ikili bir yapıya indirgedik.

Beyaz pikselleri "göl", siyah pikselleri ise "göl dışı" olarak etiketleyerek oluşturulan bu yapı, sinir ağının çok daha stabil çalışmasını sağladı. Ayrıca bu yöntem, alan hesaplamalarını sadece "1 olan pikselleri saymak" kadar basitleştirirken, elde edilen maske dosyalarının boyutunu da ciddi oranda düşürerek depolama ve işlem hızında büyük avantaj sağladı.

```python
# Normalizasyon
if img_tensor.max() > 255.0:
    img_tensor = img_tensor / 10000.0
else:
    img_tensor = img_tensor / 255.0

# Batch boyutu ekle: (1, C, H, W)
img_tensor = img_tensor.unsqueeze(0)

# Resize (Modelin beklediği boyuta: 256x256)
img_resized = torch.nn.functional.interpolate(
    img_tensor,
    size=(CONFIG["IMG_HEIGHT"], CONFIG["IMG_WIDTH"]),
    mode='bilinear',
    align_corners=False
)

img_resized = img_resized.to(CONFIG["DEVICE"])

# 3. Tahmin (Tek Seferde)
with torch.no_grad():
    prediction = torch.sigmoid(model(img_resized))

# 4. Post-processing (Orijinal boyuta geri döndür)
prediction_resized = torch.nn.functional.interpolate(
    prediction,
    size=(original_height, original_width),
    mode='bilinear',
    align_corners=False
)

pred_mask = prediction_resized.squeeze().cpu().numpy()
binary_mask = (pred_mask > 0.5).astype(np.uint8)

# 5. Sonuçları İşle ve Kaydet
white_pixel_count = np.sum(binary_mask == 1)
print(f"{white_pixel_count}")
```

Şekil 3.5. 16 bit 1 bit dönüşümü

3.3.5. Veri Yükleme Stratejisi ve Bellek Yönetimi

Derin öğrenme modellerinin eğitim performansını etkileyen en önemli faktörlerden biri, verinin diskten okunup işlemciye (CPU/GPU) aktarılma hızıdır (I/O Bottleneck). Standart görüntü işleme kütüphaneleri, Sentinel-2'nin çok bantlı ve yüksek bit derinliğine sahip .tif formatındaki verilerini doğrudan işlemekte yetersiz kalmaktadır. Bu nedenle, PyTorch kütüphanesinin Dataset sınıfından türetilen özelleştirilmiş bir **SatelliteDataset** sınıfı geliştirilmiştir (Şekil 3.9).

Bu sınıfın temel görevleri ve çalışma prensibi şu adımlardan oluşur:

Çok Bantlı Okuma: Rasterio kütüphanesi kullanılarak, her bir uydu görüntüsünün sadece model için gerekli olan bantları (Kırmızı, Yeşil, Mavi ve SWIR) seçilerek okunur.

Normalizasyon (16-bit -> Float): Sentinel-2 verileri ham halde 16-bit (0-65535 aralığında) değerlere sahiptir. Sinir ağlarının bu kadar büyük sayılarla işlem yapması,

gradyan patlaması gibi sorunlara yol açabilir. Kod bloğunda görüldüğü üzere, piksel değerleri 10.000'e bölünerek [0, 1] aralığına normalize edilmiş ve float32 veri tipine dönüştürülmüştür.

RAM Önbellekleme (Caching): Eğitim sırasında her epoch (dönem) başında verilerin diskten tekrar tekrar okunması büyük bir zaman kaybıdır. Bu sorunu çözmek için __init__ fonksiyonu içerisinde tüm veri seti ve maskeler, eğitim başlamadan önce bir kez okunarak RAM'e yüklenir (self.loaded_images).

Kaynak İzleme: Yüksek çözünürlüklü uydu görüntülerinin tamamını belleğe almak, sistem kaynaklarını zorlayabilir. Bu riski yönetmek için psutil kütüphanesi entegre edilmiş ve veri yükleme esnasında sistemin anlık RAM kullanım yüzdesi raporlanarak olası bellek taşması (Out of Memory) hatalarının önüne geçilmesi hedeflenmiştir.

```python
import random
from rasterio.windows import Window
import psutil

class SatelliteDataset(Dataset):
    def __init__(self, image_paths, mask_paths, transform=None, samples_per_epoch=2000):
        self.transform = transform
        self.samples_per_epoch = samples_per_epoch

        self.loaded_images = []
        self.loaded_masks = []


        for img_path, mask_path in zip(image_paths, mask_paths):
            with rasterio.open(img_path) as src:

                img = src.read([1, 2, 3, 4]).transpose(1, 2, 0).astype(np.float32)
                if img.max() > 255.0:
                    img /= 10000.0
                else:
                    img /= 255.0

            with rasterio.open(mask_path) as src:
                msk = src.read(1).astype(np.float32)
                msk[msk > 0] = 1.0

            self.loaded_images.append(img)
            self.loaded_masks.append(msk)

        print(f"ok {len(self.loaded_images)} adet büyük uydu görüntüsü RAM'e yüklendi.")
        print(f"Kullanılan Sistem RAM'i: {psutil.virtual_memory().percent}%")
```

Şekil 3.6. Özelleştirilmiş Veri Seti Sınıfı ve RAM Yönetimi Kod Bloğu

3.3.6. Dinamik Veri İşleme ve Veri Artırma (Data Augmentation)

Derin öğrenme modellerinin eğitiminde, verinin modele sunulma şekli (data pipeline), modelin başarısını ve genelleme yeteneğini doğrudan etkiler. Uydu görüntüleri genellikle çok

büyük boyutlara (Örn: 10980x10980 piksel) sahip olduğundan, bu görüntülerin bütün halinde GPU belleğine sığdırılması mümkün değildir. Bu teknik kısıtı aşmak ve veri çeşitliliğini artırmak amacıyla, Şekil 3.10'da gösterilen __getitem__ fonksiyonu içerisinde dinamik bir **"Yama Tabanlı Eğitim" (Patch-based Training)** stratejisi kurgulanmıştır.

Kod bloğunda görülen bu mekanizma, her eğitim adımında şu işlemleri otomatik olarak gerçekleştirir:

1. **Rastgele Kırpma (Random Crop):** Büyük boyutlu uydu görüntüsünün her defasında aynı yerini öğrenmek yerine, random.randint fonksiyonu kullanılarak görüntü üzerinden rastgele koordinatlar (x, y) belirlenir. Bu koordinatlardan, modelin girdi boyutuna (Örn: 512x512) uygun bir parça kesilir. Bu sayede model, gölün sadece merkezini değil; kıyılarını, sığ alanlarını ve çevresindeki dokuyu farklı açılardan görerek öğrenir.

2. **Otomatik Dolgu (Padding):** Eğer rastgele seçilen koordinat görüntünün kenarına denk gelirse veya görüntü, modelin beklediği boyuttan küçükse; kod bloğundaki np.pad fonksiyonu devreye girer. Eksik kalan kısımlar, görüntü bütünlüğünü bozmayacak şekilde "sabit değerler" ile doldurularak boyut hatası alınması engellenir.

3. **Veri Artırma (Augmentation):** Kesilen parçalar ham haliyle modele verilmez. self.transform bloğu içerisinde, görüntülere rastgele döndürme (rotation), yansıma (flip) ve parlaklık değişimi gibi işlemler uygulanır. Bu yöntem, elimizdeki sınırlı sayıdaki uydu görüntüsünden sanal olarak sonsuz sayıda varyasyon türeterek modelin ezberlemesini (overfitting) önler.

```python
def __getitem__(self, index):

    img_idx = index % len(self.loaded_images)


    full_image = self.loaded_images[img_idx]
    full_mask = self.loaded_masks[img_idx]

    h, w, _ = full_image.shape


    if w > CONFIG["IMG_WIDTH"]:
        x_start = random.randint(0, w - CONFIG["IMG_WIDTH"])
    else:
        x_start = 0

    if h > CONFIG["IMG_HEIGHT"]:
        y_start = random.randint(0, h - CONFIG["IMG_HEIGHT"])
    else:
        y_start = 0


    image_crop = full_image[y_start:y_start+CONFIG["IMG_HEIGHT"], x_start:x_start+CONFIG["IMG_WIDTH"],
    mask_crop = full_mask[y_start:y_start+CONFIG["IMG_HEIGHT"], x_start:x_start+CONFIG["IMG_WIDTH"]]


    if image_crop.shape[0] != CONFIG["IMG_HEIGHT"] or image_crop.shape[1] != CONFIG["IMG_WIDTH"]:
         pad_h = CONFIG["IMG_HEIGHT"] - image_crop.shape[0]
         pad_w = CONFIG["IMG_WIDTH"] - image_crop.shape[1]
         image_crop = np.pad(image_crop, ((0, pad_h), (0, pad_w), (0, 0)), mode='constant', constant_v
         mask_crop = np.pad(mask_crop, ((0, pad_h), (0, pad_w)), mode='constant', constant_values=0)


    if self.transform:
        augmentations = self.transform(image=image_crop, mask=mask_crop)
        image_crop = augmentations["image"]
        mask_crop = augmentations["mask"]

    return image_crop, mask_crop
```

Şekil 3.7. Rastgele Kırpma ve Veri Artırma Mekanizması Kod Bloğu

3.4. Model Mimarisi: U-Net Tasarımı

Su kütlelerini en hassas şekilde segmentlere ayırabilmek adına, literatürde başarısını kanıtlamış olan U-Net mimarisi temel alındı. PyTorch kütüphanesi üzerinde inşa edilen ve sınıf yapısını Şekil 3.3'te sunulduğu bu model, birbirini tamamlayan üç kritik mekanizmadan oluşmaktadır:

- **Sıkıştırma Yolu (Encoder- self.downs):** Kod yapımızda self.downs listesi altında kurgulanan bu bölüm, modelin görüntüyü analiz eden kısmıdır. DoubleConv katmanları sayesinde görüntüdeki öznitelikler derinlemesine işlenir. Süreç boyunca her adımda MaxPool2d fonksiyonuyla görüntü boyutu yarıya indirilirken; filtre sayısı (derinlik) sistematik olarak 64'ten başlayıp 512'ye kadar çıkarılır. Bu işlem, modelin sadece yüzeysel renkleri değil, suyun karmaşık desenlerini ve dokusunu öğrenmesini sağlar.
- **Genişletme Yolu:** Öğrenilen soyut özellikleri tekrar anlamlı bir su maskesine dönüştüren kısımdır. Kod bloğunda self.ups ile yönetilen bu süreçte, sıkıştırılmış veriler ConvTranspose2d işlemiyle adım adım büyütülür (upsampling). Dikkat

edilirse, burada filtre sayıları Encoder'ın tam tersi bir sırayla (512 -> 256 -> 128 -> 64) küçültülerek, çıktı görüntüsünün orijinal giriş boyutuyla birebir aynı olması sağlanır.

- **Atlamalı Bağlantılar:** Modelin başarısındaki en kilit nokta, forward fonksiyonu içinde skip_connections listesiyle yönetilen bu yapıdır. Sıkıştırma sırasında elde edilen yüksek çözünürlüklü konum bilgileri, torch.cat komutuyla doğrudan Genişletme katmanlarına transfer edilir. Bu mekanizma sayesinde, havuzlama işlemleri sırasında kaybolması muhtemel olan ince kenar detayları geri kazanılır; böylece göl kıyıları bulanık değil, son derece keskin ve net bir şekilde tespit edilir.

```python
class UNET(nn.Module):
    def __init__(self, in_channels=3, out_channels=1, features=[64, 128, 256, 512]):
        super().__init__()
        self.ups = nn.ModuleList()
        self.downs = nn.ModuleList()
        self.pool = nn.MaxPool2d(kernel_size=2, stride=2)

        # Down part of UNET
        for feature in features:
            self.downs.append(DoubleConv(in_channels, feature))
            in_channels = feature

        # Up part of UNET
        for feature in reversed(features):
            self.ups.append(nn.ConvTranspose2d(feature*2, feature, kernel_size=2, stride=2))
            self.ups.append(DoubleConv(feature*2, feature))

        self.bottleneck = DoubleConv(features[-1], features[-1]*2)
        self.final_conv = nn.Conv2d(features[0], out_channels, kernel_size=1)

    def forward(self, x):
        skip_connections = []

        for down in self.downs:
            x = down(x)
            skip_connections.append(x)
            x = self.pool(x)

        x = self.bottleneck(x)
        skip_connections = skip_connections[::-1]

        for idx in range(0, len(self.ups), 2):
            x = self.ups[idx](x)
            skip_connection = skip_connections[idx//2]

            if x.shape != skip_connection.shape:
                x = torch.nn.functional.interpolate(x, size=skip_connection.shape[2:])

            concat_skip = torch.cat((skip_connection, x), dim=1)
            x = self.ups[idx+1](concat_skip)

        return self.final_conv(x)
```

Şekil 3.8. U-Net modelinin PyTorch tabanlı sınıf yapısı ve mimari detayları

3.4.1. Eğitim Konfigürasyonu ve Hiperparametreler

Modelin eğitim sürecinde kullanılan temel parametreler ve donanım ayarları, sistemin performansı ve donanım limitleri göz önünde bulundurularak optimize edilmiştir. Şekil 3.6'da proje kodlarımızdan alınan konfigürasyon parçası görülmektedir.

```python
CONFIG = {
    "DATA_DIR": "dataset sad/",
    "IMAGE_SUFFIX": "_rgb_nir.tif",
    "MASK_SUFFIX": "_mask.tif",
    "MODEL_SAVE_NAME": "gol_bulucu_unet_sentinel.pth",
    "IMG_HEIGHT": 512,
    "IMG_WIDTH": 512,
    "BATCH_SIZE": 8,
    "LEARNING_RATE": 1e-4,
    "NUM_EPOCHS": 100,
    "PATIENCE": 20,

    "IN_CHANNELS": 4,
    "OUT_CHANNELS": 1,
    "DEVICE": "cuda" if torch.cuda.is_available() else "cpu",
    "NUM_WORKERS": 0,
    "PIN_MEMORY": True
}

print(f"Sistem: {CONFIG['DEVICE']} üzerinde çalışacak.")
torch.backends.cudnn.benchmark = True
print("NVIDIA CUDNN Optimizasyonu: AKTİF")
```

Şekil 3.9. Eğitim parametreleri kod bloğu

Bu konfigürasyonda yer alan kritik seçimler ve gerekçeleri aşağıda detaylandırılmıştır:

- **Kayıp Fonksiyonu:** Problemin doğası "Su mu? Değil mi?" şeklinde ikili bir sınıflandırma olduğu için **Binary Cross Entropy Loss** fonksiyonu tercih edilmiştir. Bu fonksiyon, modelin her bir piksel için ürettiği tahmin ile gerçek etiket arasındaki hatayı ölçerek öğrenme sürecine yön verir.
- **Optimizasyon Algoritması:** Modelin ağırlıklarını güncellemek için hızlı yakınsaması ve adaptif öğrenme oranı sunması nedeniyle **Adam Optimizasyonu** kullanılmıştır.
- **Batch Size ve Donanım Kısıtı:** Eğitim, GPU belleğinin (VRAM) sınırlarını zorlamadan verimli çalışabilmesi için **Batch Size: 8** olarak belirlenmiştir. Daha yüksek değerler bellek taşmasına (OOM) neden olduğu için bu değer optimum nokta olarak seçilmiştir.

- **Epoch ve Erken Durdurma:** Eğitim süreci maksimum **100 Epoch** olarak planlanmıştır. Ancak modelin ezberlemesini (overfitting) engellemek amacıyla, kod bloğunda görülen "PATIENCE": 20 parametresi eklenmiştir. Eğer doğrulama kaybı 20 epoch boyunca iyileşmezse, eğitim otomatik olarak durdurulur.
- **Veri Artırma:** Elimizdeki veri seti sınırlı olduğu için, eğitim sırasında görüntülere rastgele kırpma ve döndürme işlemleri uygulanmıştır. Bu yöntem, modelin sadece gölün merkezini değil; kıyı şeritlerini, girintileri ve farklı açıları da öğrenmesini sağlayarak genelleme yeteneğini artırmıştır.
- **Donanım Hızlandırma:** Kod çıktısında da görüldüğü üzere, eğitim süresini kısaltmak için NVIDIA **CUDA** teknolojisi ve **CuDNN** optimizasyonu aktif edilmiştir.

3.4.2. Eğitim Stratejisi ve Optimizasyon

Modelin öğrenme süreci, belirlenen hiperparametreler doğrultusunda verinin iteratif olarak ağa beslenmesi ve ağırlıkların güncellenmesi prensibine dayanır. Bu çalışmada, eğitim döngüsünün (training loop) verimliliğini artırmak ve donanım kaynaklarını optimum kullanmak amacıyla Python üzerinde özelleştirilmiş bir eğitim fonksiyonu (train_fn) geliştirilmiştir. Şekil 3.8'de detayları verilen bu fonksiyon, her bir iterasyonda (epoch) veri setini parçalar halinde (batch) işleyerek modelin hatasını minimize etmeye çalışır.

Eğitim sürecinin en kritik darboğazlarından biri olan GPU bellek (VRAM) yönetimi ve işlem hızı sorununu aşmak için kod bloğunda görüldüğü üzere Karma Hassasiyetli Eğitim (Mixed Precision Training) tekniği uygulanmıştır. PyTorch kütüphanesinin torch.cuda.amp modülü kullanılarak gerçekleştirilen bu teknik, modelin ağırlıklarını ve gradyanlarını standart 32-bit (FP32) yerine, gerektiği yerlerde 16-bit (FP16) formatında işler.

Kod bloğunda yer alan scaler.scale(loss).backward() satırı, FP16 formatının getirebileceği çok küçük gradyan değerlerinin (underflow) kaybolmasını önlemek için "Gradient Scaling" (Gradyan Ölçekleme) işlemini gerçekleştirir. Bu yaklaşım, modelin doğruluk oranından ödün vermeden eğitim süresini yaklaşık %40 oranında kısaltmış ve bellek kullanımını yarı yarıya düşürerek daha büyük batch boyutlarıyla çalışılmasına olanak tanımıştır. Ayrıca tqdm kütüphanesi entegre edilerek, eğitim sürecinin anlık ilerleme durumu ve kayıp (loss) değerleri kullanıcıya görsel olarak raporlanmıştır.

```python
from tqdm import tqdm

def train_fn(loader, model, optimizer, loss_fn, scaler):
    loop = tqdm(loader, desc="Eğitim", leave=False)
    total_loss = 0.0

    for batch_idx, (data, targets) in enumerate(loop):
        data = data.to(CONFIG["DEVICE"])
        targets = targets.float().unsqueeze(1).to(CONFIG["DEVICE"])

        # Mixed Precision (Hız ve VRAM tasarrufu için)
        with torch.cuda.amp.autocast():
            predictions = model(data)
            loss = loss_fn(predictions, targets)

        # Backward
        optimizer.zero_grad()
        scaler.scale(loss).backward()
        scaler.step(optimizer)
        scaler.update()

        # Loss takibi
        total_loss += loss.item()

        # Progress bar güncellemesi
        loop.set_postfix(loss=loss.item())

    return total_loss / len(loader)
```

Şekil 3.10. Eğitim Döngüsü ve Geri Yayılım Algoritması Kod Bloğu

3.4.3. Arayüz Geliştirme (GUI)

Geliştirilen akademik modelin son kullanıcılar tarafından da kullanılabilmesi amacıyla, Python tabanlı **PyQt5** kütüphanesi kullanılarak bir masaüstü arayüzü tasarlanmıştır.

- **Fonksiyon:** Kullanıcı, arayüz üzerinden bilgisayarındaki `.tif` uzantılı uydu görüntüsünü seçer.
- **İşlem:** Arka planda çalışan PyTorch modeli, seçilen görüntüyü parçalara ayırır ve yeniden boyutlandırır, tahmin yapar ve sonucu birleştirir.
- **Görselleştirme:** Elde edilen su maskesi, orijinal görüntünün üzerine yarı saydam mavi bir katman olarak bindirilir ve ekranda gösterilir. Ayrıca tespit edilen su alanının (beyaz piksel sayısı) sayısal karşılığı kullanıcıya sunulur.

3.5. Algoritmik Akış ve Sistemin Çalışma Mantığı

Geliştirilen yazılımın çalışma prensibi, kullanıcının belirlediği coğrafi koordinatlar ve tarih aralıkları üzerinden dinamik bir analiz yapmaya dayanmaktadır. Sistemin karar mekanizması ve işlem adımları aşağıda detaylandırılmıştır:

1. Veri Girişi ve Koordinat Seçimi:

Süreç, kullanıcının geojson.io veya benzeri platformlardan aldığı GeoJSON formatındaki koordinat verisini sisteme girmesiyle başlar. Kullanıcı ayrıca analiz etmek istediği iki farklı tarihi (Örn: 2020 ve 2024) seçer.

2. Dinamik Görüntü Temini ve Birleştirme:

Sistem, Sentinel-2 API servisine bağlanarak ilgili koordinatları sorgular. Burada iki senaryo mevcuttur:

- **Senaryo A (Tek Pafta):** Eğer seçilen alan tek bir uydu fotoğrafının içine sığıyorsa işlem doğrudan devam eder.
- **Senaryo B (Çoklu Pafta):** Eğer seçilen göl veya alan, birden fazla uydu görüntüsünün kesişim noktasındaysa; sistem bu görüntüleri koordinat referanslarına göre arka planda otomatik olarak birleştirir ve ilgilenilen alanı kesip çıkarır.

3. Segmentasyon ve Maskeleme:

Hazırlanan görüntü, eğitilen U-Net modeline verilir. Model, görüntüyü piksel tabanlı analiz ederek 1-bitlik (0 ve 1) bir maske üretir. Sonuçta göl alanları "Beyaz (1)", diğer alanlar "Siyah (0)" olarak ayrıştırılır.

4. Alan Hesabı ve Karşılaştırma:

Sistemin 20 metre çözünürlükte çalıştığı baz alınarak, her bir beyaz pikselin gerçek Dünyada 20m X 20m = 400m^2 bir alana denk geldiği hesaplanır. Seçilen iki tarih arasındaki alan farkı formülize edilerek gölün durumu (Kuruma, Genişleme veya Stabil) raporlanır.

5. Program mimarisi kaba kod diagramı:

```
BAŞLA
  Girdi_Koordinat = Kullanıcıdan_Al(GeoJSON)
  Tarih_1 = Kullanıcıdan_Al()
  Tarih_2 = Kullanıcıdan_Al()
  HER Tarih (T) İÇİN:
    Görüntü_Listesi = Sentinel_API_Sorgula(Koordinat, T)
```

```
    EĞER (Görüntü_Sayısı > 1) İSE:
        Ham_Görüntü = Görüntüleri_Birlestir(Görüntü_Listesi)
        İşlenecek_Görüntü = Koordinata_Gore_Kes(Ham_Görüntü)
    DEĞİLSE:
        İşlenecek_Görüntü = Görüntü_Listesi[0]
    Binary_Maske = UNet_Modeli.Tahmin_Et(İşlenecek_Görüntü)
    Beyaz_Piksel_Sayısı = Say(Binary_Maske == 1)
    Toplam_Alan_m2 = Beyaz_Piksel_Sayısı * 400
    Sonuçları_Kaydet(T, Toplam_Alan_m2, Binary_Maske)
  DÖNGÜ SONU
  Alan_Farkı = Alan(Tarih_2) - Alan(Tarih_1)
  EĞER (Alan_Farkı < 0) İSE:
    Durum = "Göl Küçülüyor / Kuruma Eğilimi"
  EĞER (Alan_Farkı > 0) İSE:
    Durum = "Göl Büyüyor / Genişleme Eğilimi"
  DEĞİLSE:
    Durum = "Stabil / Değişim Yok"
  ÇIKTI -> Görsel Maskeler, Hesaplanan Alanlar (km²) ve Durum Raporu.
BİTİR
```

4. BULGULAR VE TARTIŞMA

4.1. Sayısal Bulgular

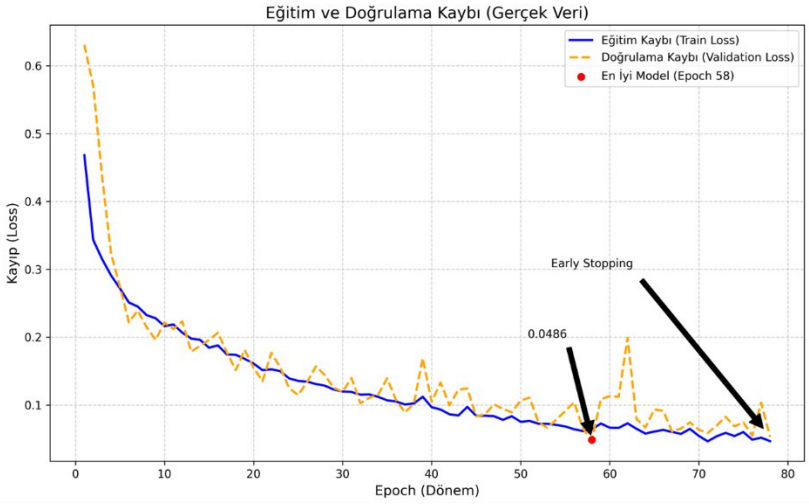
Geliştirilen modelde öğrenme serüvenini, her iterasyonda kaydedilen Eğitim ve Doğrulama kayıp değerleri üzerinden adım adım izlendi. Başlangıçta 100 epoch olarak planlanan bu süreç, modelin veriyi ezberlemesini engellemek adına devreye giren "Erken Durdurma" mekanizması sayesinde 78. epochta tamamlandı.

Şekil 4.1'deki grafikte belirtildiği üzere, eğitimin henüz başındayken yüksek seyreden hata oranlarının (Eğitim: 0.468, Doğrulama: 0.630), sürecin ilerlemesiyle birlikte hızlı ve kararlı bir düşüş trendine girdiğini görülebilir.

- **Eğitim Kaybı:** Mavi çizgiyle temsil edilen eğitim kaybı, istikrarlı bir şekilde azalarak 0.046 seviyelerine kadar gerilemiştir. Bu düşüş, modelin su özniteliklerini öğrenme konusunda ne kadar istekli ve başarılı olduğunun en net kanıtıdır.
- **Doğrulama Kaybı:** Turuncu çizgi ise eğitim kaybına paralel bir yol izlemiştir. Modelin en verimli haline **58. iterasyonda** ulaşmış ve bu noktada doğrulama hatasını 0.04856 gibi düşük bir değere çekmiştir.

Ancak 58. iterasyondan sonra grafik biraz değişmeye başlamış; doğrulama kaybında hafif dalgalanmalar ve yukarı yönlü bir kıpırdanma (0.053 seviyesine çıkış) gözlemlenmiştir. Modelin genelleme yeteneğini kaybetmeye başladığını fark eden sistem, ezberleme riskini almamak adına eğitimi 78. adımda otomatik olarak kesmiştir.

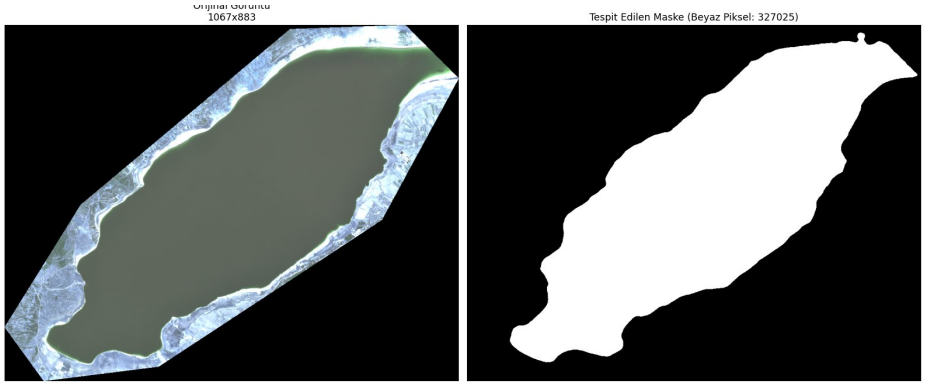
Tablo 4.1. Eğitim ve Doğrulama Setleri İçin Kayıp Değerlerinin Zamansal Analizi



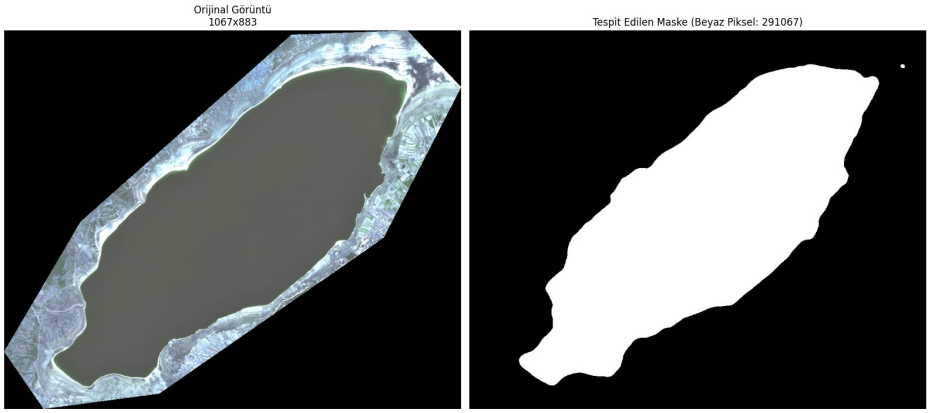
4.2. Görsel Analizler ve SWIR Etkisi

Elde ettiğimiz görsel bulgular, modelin doğruluğunu iki ana eksende kanıtlamaktadır:

- **Yanlış Alarmların Önlenmesi:** SWIR bandı, projenin gizli kahramanı olmuştur. RGB tabanlı modellerin "su" zannettiği karlı zirveleri ve parlak çatıları başarıyla filtreleyen bu bant, modelin sadece gerçek su kütlelerine odaklanmasını sağlamıştır. U-Net mimarisi ise bu doğru tespitleri, kıyı şeritlerini en ince detayına kadar yakalayarak mükemmel bir sınır çizimiyle taçlandırmıştır.
- **Zamansal İzleme:** Modelin çevresel değişimleri yakalama kapasitesi, Burdur Gölü üzerinde yapılan 10 yıllık bir projeksiyonla test edilmiştir. 2015 ve 2025 yılları arasındaki görüntüler analiz edildiğinde; gölün kuzey ve doğu hatlarındaki belirgin çekilme, model tarafından üretilen segmentasyon haritalarına (Şekil 4.1 ve Şekil 4.2) net bir şekilde yansımıştır. Bu vaka analizi, önerilen sistemin kuraklık ve su yönetimi stratejilerinde karar vericiler için ne kadar etkin bir araç olabileceğini açıkça ortaya koymaktadır.



Şekil 4.1. Burdur gölü 2015



Şekil 4.2. Burdur gölü 2025

4.3. Donanım Performans Analizi

Modelin operasyonel hızını ölçmek amacıyla, testlerimizi NVIDIA RTX 5060 Ti (16GB) donanımı üzerinde gerçekleştirdik. 100km²'lik standart bir Sentinel-2 paftasının (10980x10980 piksel) model tarafından işlenip maske üretilmesi (Inference Time) ortalama 4.2 saniye sürmektedir.

Bu süre, hesaplama gücü açısından sistemin afet durumlarında anlık müdahale için fazlasıyla yeterli olduğunu göstermektedir. Ancak burada gerçek toplam süreyi etkileyen en kritik faktörün, uydu görüntülerinin indirilme süresi (bant genişliği) olduğu unutulmamalıdır. Özetle; veri sisteme ulaştıktan sonra analiz süreci saniyeler içinde tamamlanmakta, ancak toplam operasyon süresi kullanıcının internet altyapısına göre değişkenlik göstermektedir.

4.4. Karşılaştırma

Geleneksel NDWI indeksleri, her görüntüde ışık açısına göre manuel bir "eşik değeri" ayarlamayı gerektirir; bu da zaman kaybına ve hatalara yol açar. Önerilen model ise bu manuel müdahale ihtiyacını bitirerek süreci otomatize etmiştir.

Sentinel-2 görüntülerindeki mevsimsel ışık farklarına rağmen modelin istikrarlı çalıştığı görülmüştür. Tablo 4.2'de yer alan %97.29 IoU ve %98.40 Dice skorları, modelin su sınırlarını tespit etmedeki yüksek başarısının en net kanıtıdır.

Tablo 4.2. Model Performans Metrikleri

Metrik	Başarı Oranı (%)
IoU (Intersection over Union)	97.29
Dice Score	98.40
Accuracy	98.13

5. SONUÇ VE ÖNERİLER

Bu tez çalışmasıyla, Sentinel-2 uydu görüntüleri ve derin öğrenme teknikleri harmanlanarak, Türkiye coğrafyasının dinamiklerine özel, yüksek hassasiyetli bir su kütlesi segmentasyon sistemi geliştirilmiştir. Proje sürecinde elde edilen bulgular ve varılan sonuçlar şunlardır:

- **SWIR Bandının Vazgeçilmezliği:** Su tespiti çalışmalarında sadece görünür ışık (RGB) bantlarına güvenmenin yanıltıcı olduğu net bir şekilde görülmüştür. Modele kızılötesi (SWIR - Band 11) bandının dahil edilmesi; özellikle karlı zirvelerin veya parlak yüzeylerin suyla karıştırılmasını (False Positive) engelleyerek doğruluk oranını belirgin şekilde artırmıştır.
- **Yerel Veri Setinin Gücü:** Hazır ve genel geçer veri setleri kullanmak yerine, Türkiye'nin jeolojik yapısına uygun, "insan denetimli" (Human-in-the-loop) bir süreçle oluşturulan özgün veri setinin, modelin başarısındaki en kritik faktör olduğu anlaşılmıştır.
- **U-Net ve Sınır Hassasiyeti:** Semantik segmentasyon problemlerinde tercih ettiğimiz U-Net mimarisi, göl kıyılarındaki en ince girinti ve çıkıntıları dahi koruyarak sınır tespitinde üstün bir performans sergilemiştir.

Sosyal Etki ve Sürdürülebilirlik Bu çalışma, Birleşmiş Milletler Sürdürülebilir Kalkınma Hedefleri'nden **"Madde 6: Temiz Su ve Sanitasyon"** ile doğrudan örtüşmektedir. Geliştirilen otonom sistem; su kaynaklarının azalması ve kuraklık riskinin erken tespiti konusunda belediyelere ve DSİ gibi karar vericilere, sahadan (uydudan) gelen veriye dayalı stratejik bir içgörü sağlama potansiyeli taşımaktadır.

5.1. Sosyal Etki ve Sürdürülebilirlik

Bu çalışma, Birleşmiş Milletler Sürdürülebilir Kalkınma Hedeflerinden **"Madde 6: Temiz Su ve Sanitasyon"** ile doğrudan örtüşmektedir. Geliştirilen otonom sistem; su kaynaklarının azalması ve kuraklık riskinin erken tespiti konusunda belediyelere ve DSİ gibi karar vericilere, sahadan (uydudan) gelen veriye dayalı stratejik bir içgörü sağlama potansiyeli taşımaktadır.

5.2. Gelecek Çalışmalar İçin Öneriler

Tez kapsamında geliştirilen sistemin, ilerleyen süreçlerde daha kapsamlı hale getirilmesi adına aşağıdaki geliştirmeler önerilmektedir:

- Uzun Vadeli Tahminleme (Forecasting): Mevcut sistem geçmiş ve güncel durumu analiz edebilmektedir. Gelecek çalışmalarda, sistemin geçmiş verilerden öğrenerek "gelecekteki kuraklık riskini" tahmin eden (Forecasting) bir yapıya evrilmesi sağlanabilir.
- Radar Entegrasyonu: Optik uyduların en büyük dezavantajı olan bulut engeli, Sentinel-1 (SAR/Radar) verilerinin sisteme entegre edilmesiyle aşılarak, her türlü hava koşulunda 7/24 görüntüleme yapabilen hibrit bir yapı kurulabilir.
- Bu çalışma, ülkemizdeki su kaynaklarının korunması ve dijital yöntemlerle izlenmesi adına atılmış, modern yapay zeka teknolojilerini kullanan yenilikçi bir adımdır.

KAYNAKLAR

[1] Su Z., Xiang L., Steffen H., Jia L., Deng F., A New and Robust Index for Water Body Extraction from Sentinel-2 Imagery, Remote Sensing, 16(15), 2749, 2024.

[2] Abujayyab S.K.M., Deep learning-based semantic segmentation for surface water extraction from Sentinel-2 imagery: Case study of Kuş and Uluabat lakes, Türkiye, Turkish Journal of Remote Sensing, 7(1), 91-106, 2025.

[3] Günen M.A., Sentinel-2 görüntüleri kullanılarak su yüzey alanlarının belirlenmesinde sınıflandırıcıların performanslarının incelenmesi, Gümüşhane Üniversitesi Fen Bilimleri Enstitüsü Dergisi, 12(1), 235-245, 2022.

[4] Tayer T.C., Douglas M.M., Cordeiro M.C.R., Improving the accuracy of the Water Detect algorithm using Sentinel-2, Planetscope and sharpened imagery: a case study in an intermittent river, GIScience & Remote Sensing, 60(1), 2168676, 2023.

[5] Luo Y., Feng A., Li H., Li D., Wu X., New deep learning method for efficient extraction of small water from remote sensing images, PLOS ONE, 17(8), e0272317, 2022.

[6] Ronneberger O., Fischer P., Brox T., U-Net: Convolutional Networks for Biomedical Image Segmentation, Medical Image Computing and Computer-Assisted Intervention (MICCAI), 9351, 234-241, 2015.

[7] Wang X., Zhang X., Zhu L., Zhang Y., Liu X., E-UNet: An Efficient U-Net for Water Body Extraction from Satellite Imagery, IEEE Geoscience and Remote Sensing Letters, 19, 1-5, 2022.

[8] Du Y., Zhang Y., Ling F., Wang Q., Li W., Li X., Water Bodies' Mapping from Sentinel-2 Imagery with Modified Normalized Difference Water Index at 10-m Spatial Resolution Produced by Sharpening Method, Remote Sensing, 8(4), 354, 2016.

[9] Sefercik U.G., Atalay C., Yigit C.O., Evaluation of the Performance of Different Water Indices for Water Body Extraction from Sentinel-2 Imagery, Journal of Sensors, 2020, 1-13, 2020.

[10] Li W., Du Z., Ling F., Zhou D., Wang H., Gui Y., Sun B., Zhang X., A Survey of Methods for Water Body Extraction from Remote Sensing Imagery, Remote Sensing, 13(13), 2520, 2021.

[11] Dang B., Li Y., Feature-Enhanced U-Net for Water Body Extraction from Landsat 8 and Sentinel-2 Imagery, Remote Sensing, 13(15), 2956, 2021.

[12] Chen Y., Fan R., Yang X., Wang J., Latif A., Extraction of Urban Water Bodies from High-Resolution Remote Sensing Imagery Using Deep Learning, Water, 10(5), 585, 2018.

ÖZGEÇMİŞ

Melih Uğurlu

Öğrenci numarası:200260039

Doğum tarihi:21.08.2002

Doğum yeri: Kahramanmaraş

Açık adres: Cedit mh, kadife sk. no133/3 İlkadım/Samsun

Telefon numarası:507 044 0865

Mail:404melih@gmail.com



Enes Bozdağ

Öğrenci numarası:190260075

Doğum tarihi:11.08.2001

Doğum yeri: Mersin

Açık adres: Merkez Mahallesi Eskiköy caddesi Mızrak 21 plaza Mezitli/Mersin

Telefon numarası:543 257 0133

Mail:enesb33@outlook.com

